



中山大學
SUN YAT-SEN UNIVERSITY

信息安全技术课程期末报告

基于逐 Token KL 约束与匹配检测的 大语言模型文本水印实验研究

基于 KGW 的复现、改进与 clean test-500 验证

学生姓名： 施煌，祖裕柏，黄镇邦
学号： 23336204, 23344188, 23342035
院系： 计算机学院

2026 年 7 月

摘要

本文面向大语言模型生成文本的来源识别问题, 复现 Kirchenbauer 等人提出的 KGW 统计水印, 并在统一、可审计的实验协议下研究逐位置 KL 约束水印。KGW 以固定偏置 δ 提高 green token 的采样概率, 检测简单但无法直接约束不同上下文位置的分布扰动。为此, 本文采用 CA-KL: 对每个生成位置求解满足 $D_{\text{KL}}(Q_t \| P_t) \leq \varepsilon$ 的最大偏置 δ_t , 使水印强度由可解释的逐 token KL 预算控制; 在完整方法 CA-KL-CG 中进一步加入 candidate-aware greenlist、confidence gate 与配置严格匹配的 weighted detector。

实验从 C4/realnewslike 构造互不重叠的 validation/test 各 500 条记录, 在 OPT-1.3B、200 个生成 token、 $\gamma = 0.25$ 、temperature 1.0、top-k 0、top-p 1.0 的统一配置下完成参数选择与 test-500 $\times$ 3 seeds 独立评测。检测阈值由 validation human completions 校准; test human completions 的实际 FPR 为 0.6%。不确定性采用 2,000 次 prompt-cluster bootstrap 估计。

最终结果显示, CA-KL 的 ε 从 0.02 增至 0.50 时, TPR@1%FPR 从 29.67% 增至 99.53%, 同时 SimCSE 从 0.7218 降至 0.6566、corpus PPL 从 22.97 增至 34.14, 呈现清晰的检测-质量折中。在预注册的 $\varepsilon = 0.10$ 工作点上, CA-KL 达到 94.80% TPR@1%FPR、0.6875 SimCSE 和 25.25 corpus PPL; KGW $\delta = 1.0$ 为 92.27%、0.6901 和 23.97。两条曲线在局部接近, 但现有区间不足以支持“CA-KL 严格改善 KGW Pareto 前沿”的强结论。对于 validation 选定的 CA-KL-CG, standard KGW detector 的 TPR 为 86.40%, matched weighted-global detector 则达到 97.80%, 表明检测配置与 candidate/gate 生成逻辑的一致性直接影响统计功效。总体而言, CA-KL 提供了连续的检测-质量工作曲线, 匹配检测显著恢复了完整方法的水印证据, 但 clean 条件下尚不能宣称全面优于 KGW 固定偏置包络。

关键词: 大语言模型; 文本水印; KGW; KL 散度; 匹配检测; 低误报率校准

目录

1	引言	1
2	KGW 方法与复现	1
2.1	Seeded greenlist 与固定偏置	1
2.2	官方链路复现	1
3	逐位置 KL 约束与匹配检测	2
3.1	逐位置 KL 预算	2
3.2	候选集合与置信门控	3
3.3	匹配检测器	3
4	实验设计	3
4.1	数据集与任务构造	3
4.2	模型与参数设置	3
4.3	实验步骤	4
4.4	评价指标与统计方法	4
4.5	代码运行证明	4
5	实验结果	5
5.1	Validation 集上的参数选择	5
5.2	独立测试集上的 KGW 与 CA-KL	6
5.3	完整方法与匹配检测	8
6	总结	8
7	实验分工	8

1 引言

生成式大语言模型已经广泛进入写作、问答、教育和内容平台。模型文本与人工文本在表面形式上日益接近，使内容归属、批量生成识别和后续审计变得困难。文本水印的目标是在不增加可见标记的情况下，通过受密钥控制的生成概率偏置，在文本中留下可重复检验的统计证据。与训练一个通用 AI 文本分类器相比，生成式水印直接利用模型端密钥和生成过程，检测假设更明确，也更适合回答“该文本是否由某个受控模型生成”。

本文以 ICML 2023 的 KGW 水印为复现对象 [1]。原方法在每一步将词表按密钥划分为 greenlist 与 redlist，并给 greenlist logits 加固定偏置。固定偏置的优势是实现和统计简单，但同一个 δ 在不同 next-token 分布上对应不同的真实扰动：模型非常确定时，推动其转向 green token 的代价可能很大；候选较多时，相同偏置又可能较温和。由此，本文研究逐位置 KL 预算能否比固定 δ 提供更可解释的检测-质量折中。

本文的主要工作如下：

1. 完成 KGW 官方生成-检测链路复现，并保留其 seeded greenlist 与标准 z-score 作为共同基线；
2. 建立结构化数据、全词表 greenlist、精确 PPL/SimCSE 计分、detector pairing 与 held-out calibration 组成的可复现实验流程；
3. 在 test-500 $\times$ 3 seeds 上比较 7 个 KGW fixed-delta 点和 7 个 CA-KL epsilon 点，并报告 held-out FPR、主质量指标和 prompt-cluster bootstrap 区间；
4. 对 validation 选定的 CA-KL-CG 与 matched KGW-CG 对照分别使用 standard、weighted-global 和 weighted-winmax 检测，分析生成逻辑与检测器匹配的作用。

2 KGW 方法与复现

2.1 Seeded greenlist 与固定偏置

设基础语言模型在位置 t 的条件分布为 $P_t(v) = P(v | x_{<t})$ ，词表为 $\mathcal{V}$ 。KGW 用密钥和前缀 $x_{<t}$ 产生伪随机种子，将 $\gamma|\mathcal{V}|$ 个 token 划入 greenlist G_t 。若原 logits 为 $l_t(v)$ ，固定偏置生成分布使用

$$l'_t(v) = l_t(v) + \delta \mathbf{1}[v \in G_t].$$

检测端使用同一密钥逐位置重建 G_t 。对长度为 T 的待测文本，若观测到 N_G 个 green token，则标准 KGW 统计量为

$$z = \frac{N_G - \gamma T}{\sqrt{T\gamma(1-\gamma)}}.$$

无水印零假设下，green token 比例应接近 γ ；显著偏高的 z 支持水印假设。本文始终令 $\gamma = 0.25$ ，并对 standard detector 的阈值在 validation human completions 上独立校准，而不是把固定的 $z > 4$ 当作正式低 FPR 结论。可靠性研究同样强调阈值校准、误报率与文本长度的重要性 [2]。

2.2 官方链路复现

复现阶段按官方仓库完成最小模型和 OPT 模型的生成-检测链路验证，并处理新版 Gradio 的接口兼容问题。图 1 展示了一次典型 Demo：无水印文本的 green fraction 为 22.2%、 $z = -0.638$ ；带水印文本的 green fraction 为 70.4%、 $z = 10.4$ 。该结果确认密钥播种、greenlist 重建、logits 偏置与检测统计量能够端到端工作。




图 1: KGW 官方 Demo 的生成与检测复现。

3 逐位置 KL 约束与匹配检测

KGW 水印通过固定 logit 偏置提高 green token 的采样概率，其检测统计量简洁、可复现性强，但固定 δ 并不直接对应固定的分布扰动。对同一个 δ ，当基础模型在当前位置的分布更尖锐时，水印需要以更大的概率改变换取 green token 增益；当分布更平坦或候选 token 较多时，相同偏置造成的改变又相对温和。因此，本文将水印强度从固定偏置改写为逐位置 KL 预算，使每个生成位置的采样分布变化都由同一个可解释的上界控制，并进一步结合候选集合、置信门控和匹配检测器，使嵌入端与检测端围绕同一组条件分布完成统计判断。

在生成位置 t ，基础语言模型首先给出条件分布 $P_t(v) = P(v | x_{<t})$ ；随后密钥和当前前缀共同确定可嵌入 token 的 greenlist，并由候选集合与置信门控决定当前位置是否施加水印。若该位置被选为可嵌入位置，算法求解满足逐 token KL 约束的最大偏置 δ_t ，据此得到水印采样分布 Q_t 并生成下一个 token；若当前位置未通过门控，则保持原分布采样。检测时，检测器在相同密钥、相同基础模型和相同上下文下重建候选集合、greenlist、门控状态及其概率质量，并将每个位置的证据聚合为标准或加权统计量，最后用 validation human completions 校准的阈值判断文本是否含有水印。

3.1 逐位置 KL 预算

设原分布落在 greenlist 上的概率质量为

$$p_{G,t} = \sum_{v \in G_t} P_t(v).$$

给 green token 加偏置 δ 后，归一化常数与新 green mass 分别为

$$Z_t(\delta) = 1 + p_{G,t}(e^\delta - 1), \quad q_{G,t}(\delta) = \frac{e^\delta p_{G,t}}{Z_t(\delta)}.$$

加水印分布 $Q_{t,\delta}$ 相对原分布的正向 KL 为

$$D_{\text{KL}}(Q_{t,\delta} \| P_t) = \delta q_{G,t}(\delta) - \log Z_t(\delta).$$

CA-KL 在每个位置通过二分搜索选择

$$\delta_t = \max\{\delta \in [0, \delta_{\max}] : D_{\text{KL}}(Q_{t,\delta} \| P_t) \leq \varepsilon\},$$

其中 $\delta_{\max} = 3.0$ ， ε 是逐 token 上限，而非整段文本的总预算。该约束直接限制当前采样分布相对基础分布的改变幅度，使水印强度具有明确的分布意义。

CA-KL 的闭式 KL 定义在水印处理器接收的完整 softmax 分布上。实验采用 temperature 1.0、top-k 0 和 top-p 1.0，使处理器输出的 $Q_{t,\delta}$ 直接构成实际采样分布，避免后续温度缩放或候选截断改变概率支持集。在实现中，词表空间 $\mathcal{V}$ 以模型输出层定义，从而覆盖全部可采样 token；生成端与检测端在同一词表空间内执行密钥划分，保证 greenlist 重建的一致性。

3.2 候选集合与置信门控

仅在完整词表上划分 greenlist 会把一部分几乎不可能被采样的 token 纳入水印集合，导致有效证据与实际采样空间之间存在偏差。为此，本文引入 candidate-aware greenlist。令 C_t 为按 $P_t(v)$ 降序排列后、累计概率首次达到 candidate top-p 的最小 token 集合，算法只在 C_t 内依据密钥划分 green token，并在候选集合外保持原始采样概率。该设计使水印嵌入集中于模型当前真正可能选择的候选空间，减少低概率尾部 token 对统计证据的干扰。

置信门控用于进一步选择适合嵌入水印的位置。设 $g_t \in \{0, 1\}$ 表示当前位置是否满足 entropy/top-1 条件：当基础分布过于确定或不满足预设置信条件时，算法令 $g_t = 0$ 并取 $\delta_t = 0$ ；当 $g_t = 1$ 时，才在候选集合内求解逐位置 KL 约束下的偏置。候选集合决定水印划分的有效支持集，置信门控决定哪些位置参与嵌入，二者共同构成本文完整方法 CA-KL-CG。

3.3 匹配检测器

当生成端使用候选集合或置信门控后，传统 KGW 检测器若仍按完整词表、全位置统计 green token，会与实际嵌入机制不完全一致。因此，本文使用 matched detector 作为完整方法的主要检测器：检测端逐位置重放基础模型分布，并在相同密钥下重建 C_t 、 G_t 、 g_t 和 $p_{G,t}$ 。对于未通过门控的位置，检测器不将其作为有效水印证据；对于通过门控的位置，则按照重建后的候选空间计算 green token 偏离期望的程度。

一种一般化的 weighted z-score 可写为

$$z_w = \frac{\sum_t w_t (1[x_t \in G_t] - p_{G,t})}{\sqrt{\sum_t w_t^2 p_{G,t} (1 - p_{G,t})}},$$

其中 w_t 由模型分布和可嵌入性决定。Weighted-global 在全文范围内聚合证据；Weighted-WinMax 在多个滑动窗口上计算 z_w 并取最大值。由于窗口搜索会引入多重比较效应，Weighted-WinMax 的阈值在 validation 集上独立校准，不与 standard 或 global 检测器共享阈值。本文的评测范围为 clean generation，WinMax 用于比较不同检测证据聚合方式的效果。

4 实验设计

4.1 数据集与任务构造

数据来自 C4/realnewslike [3]。每条 source 经 OPT tokenizer 分词后保留 500–1000 token，末尾 200 token 作为 human completion，其前部保留 300–800 token 作为 prompt。数据以稳定 source ID 去重，并划分为互不重叠的 validation 与 test，各包含 500 条记录。validation 用于参数选择和检测阈值校准，test 用于最终性能评测。

4.2 模型与参数设置

生成模型为 facebook/opt-1.3b [4]，revision 为 3f5c25d0bc631cb57ac65913f76e22c2dfb61d62，FP16 推理。所有方法共享同一 prompt、生成长度、采样参数和 per-prompt 稳定 seed，配置见表 1。

表 1: 实验模型、采样参数与工作点

项目	冻结值
数据	C4/realnewslike; validation 500, test 500
Prompt / human / generation	300–800 / 200 / 200 OPT tokens
Temperature / top-k / top-p	1.0 / 0 / 1.0
Greenlist 比例 / seeding	$\gamma = 0.25$ / <code>simple_1</code>
KGW 网格	$\delta \in \{0.5, 1.0, 1.5, 1.7, 2.0, 2.5, 3.0\}$
CA-KL 网格	$\varepsilon \in \{0.02, 0.05, 0.10, 0.20, 0.30, 0.40, 0.50\}$, $\delta_{\max} = 3$
完整方法	$\varepsilon = 0.10$, candidate top-p=0.95, gate target=90%
Matched control	KGW $\delta = 1.5$, 相同 candidate 与 gate
Test base seeds	1234, 2345, 3456

4.3 实验步骤

实验按照以下四个步骤完成:

1. 在小规模样本上验证 KGW、CA-KL 与 matched detector 的实现一致性, 包括固定生成长度、 $\varepsilon = 0$ 与 No-Watermark 等价、逐步 KL 约束、PPL continuation 边界以及 SimCSE 一一配对;
2. 在 validation 集上扫描 KGW fixed-delta 与 CA-KL epsilon 网格, 并完成 candidate-only、gate-only 和 candidate+gate 消融, 根据预设规则选择完整方法参数;
3. 固定模型、采样参数、方法工作点、检测器配置和随机种子, 在 500 条 test prompts 上以三个 base seeds 生成全部比较文本;
4. 对冻结的 test 输出统一计算 standard/matched detector、corpus PPL 与 SimCSE, 并使用 2,000 次 prompt-cluster bootstrap 估计 95% 置信区间。

4.4 评价指标与统计方法

主检测指标为 TPR@1%FPR。每个 detector 均在 validation human completions 上以有限样本次序统计量确定阈值; test human completions 用于测量实际 FPR, test watermarked completions 用于测量 TPR。No-Watermark 模型文本的 model-null FPR 作为辅助统计量单独报告, human FPR 作为正式误报口径。standard KGW 的 1% 目标阈值为 $z > 2.4495$; test human FPR 为 0.6% (95% CI 0–1.4%), No-Watermark model-null FPR 为 0.8% (0.4–1.27%)。

主语义指标为 continuation-only SimCSE cosine: 对相同 prompt 和 seed, 将水印 completion 与 No-Watermark completion 一一配对, 使用 `princeton-nlp/sup-simcse-roberta-base` 自己的 tokenizer 和 pooler embedding。主分布质量指标为 continuation corpus PPL:

$$\text{PPL}_{\text{corpus}} = \exp\left(\frac{\sum_i \text{NLL}_i}{\sum_i T_i}\right),$$

只在生成 continuation 的精确 token IDs 上计分。图中的 mean row PPL 用于直观展示每条文本分布, 主表使用 corpus PPL。

95% CI 使用固定 calibration threshold 下的 2,000 次 prompt-cluster bootstrap。cluster 单位是 `prompt_id`, 同一 prompt 的三个 generation seeds 一起重采样, 因而没有把 1,500 条重复测量误当成完全独立样本。区间反映 test prompt 抽样不确定性, 不包含 validation threshold 的再次抽样不确定性。

4.5 代码运行证明

课程要求报告中包含代码运行效果截图。图 2 展示批量实验脚本在服务器端完成多方法生成、结果文件保存、PPL 计算与校准指标输出的终端日志, 其中包含最后一批 prompts 的处理进度以及结果 CSV、summary 与 calibrated metrics 的写入路径, 可作为本文实验代码完整运行的证明。

```

inform > course_project > outputs > additional > paper_controlled > paper_controlled_run.log
2974 [Prompt 495/499] CA-KL + Candidate Greenlist + Weighted/WinMax
2975 [Prompt 496/499] Generating baseline outputs...
2976 [Prompt 496/499] Fixed delta=2.0
2977 [Prompt 496/499] Adaptive delta
2978 [Prompt 496/499] CA-KL
2979 [Prompt 496/499] CA-KL + Candidate Greenlist
2980 [Prompt 496/499] CA-KL + Candidate Greenlist + Weighted/WinMax
2981 [Prompt 497/499] Generating baseline outputs...
2982 [Prompt 497/499] Fixed delta=2.0
2983 [Prompt 497/499] Adaptive delta
2984 [Prompt 497/499] CA-KL
2985 [Prompt 497/499] CA-KL + Candidate Greenlist
2986 [Prompt 497/499] CA-KL + Candidate Greenlist + Weighted/WinMax
2987 [Prompt 498/499] Generating baseline outputs...
2988 [Prompt 498/499] Fixed delta=2.0
2989 [Prompt 498/499] Adaptive delta
2990 [Prompt 498/499] CA-KL
2991 [Prompt 498/499] CA-KL + Candidate Greenlist
2992 [Prompt 498/499] CA-KL + Candidate Greenlist + Weighted/WinMax
2993 [Prompt 499/499] Generating baseline outputs...
2994 [Prompt 499/499] Fixed delta=2.0
2995 [Prompt 499/499] Adaptive delta
2996 [Prompt 499/499] CA-KL
2997 [Prompt 499/499] CA-KL + Candidate Greenlist
2998 [Prompt 499/499] CA-KL + Candidate Greenlist + Weighted/WinMax
2999 Saved 3493 rows to /home/zyb/inform/course_project/outputs/additional/paper_controlled/opt13b_paper_c4_500_t200_improved_fp32_results.csv
3000 Saved summary to /home/zyb/inform/course_project/outputs/additional/paper_controlled/opt13b_paper_c4_500_t200_improved_fp32_summary.md
3001
3002 Loading weights: 0%| | 0/517 [00:00<?, ?it/s]
3003 Loading weights: 100%| | 517/517 [00:00<00:00, 51785.24it/s]
3004 Saved PPL rows to /home/zyb/inform/course_project/outputs/additional/paper_controlled/opt13b_paper_c4_500_t200_improved_fp32_ppl_results.
3005 Saved PPL summary to /home/zyb/inform/course_project/outputs/additional/paper_controlled/opt13b_paper_c4_500_t200_improved_fp32_ppl_summa
3006 Saved independently calibrated metrics to /home/zyb/inform/course_project/outputs/additional/paper_controlled/calibration
3007 [done] Results: /home/zyb/inform/course_project/outputs/additional/paper_controlled/opt13b_paper_c4_500_t200_improved_fp32_results.csv
3008

```

图 2: 代码运行效果截图: 批量生成、PPL 计算与检测校准输出。

5 实验结果

5.1 Validation 集上的参数选择

Validation 集上的完整网格表明, KGW 和 CA-KL 均覆盖从约 30% TPR 到接近饱和的弱、中、强水印区间。CA-KL $\varepsilon = 0.10$ 取得 97.6% standard TPR@1%FPR, SimCSE 为 0.6790, 位于预注册的 95–98% operating range, 因而被选为 candidate/gate 消融的基础工作点; 其余 epsilon 用于构建完整参数曲线。

Candidate-only 的 top-p=0.90、0.95、0.99 在 matched weighted-global detector 下的 validation TPR 分别为 99.0%、99.2%、98.8%, 对应 SimCSE 为 0.6842、0.6853、0.6781; 因此选择 0.95。Gate-only 依据 No-Watermark validation 分布构造约 90%、75%、50% 三种覆盖率。最终 candidate+gate 对比见表 2, 按“先最大化 clean weighted-global TPR@1%FPR, 再比较 SimCSE”的规则选中 90% gate。

表 2: Validation 集上 candidate top-p=0.95 的 gate 参数选择

目标 gate pass	实际含义	Weighted-global TPR	SimCSE	Mean row PPL
90%	弱 gate	99.0%	0.6852	26.086
75%	中 gate	98.8%	0.6892	25.592
50%	强 gate	94.2%	0.6956	25.230

90% gate 的冻结阈值为 normalized entropy $H_{\min} = 0.0067067$ 、top-1 probability $p_{\max} = 0.9793311$ 。同时冻结 matched fixed-delta control: KGW $\delta = 1.5$ 加相同 candidate top-p 与 gate。这样可区分动态 KL 与 candidate/gate、detector 本身的贡献。

5.2 独立测试集上的 KGW 与 CA-KL

Huo 等人的 token-specific watermarking 将 detectability 与 semantic coherence 作为联合优化目标，强调水印方法不能只用单一强度下的检测率判断，而应观察不同水印强度形成的检测–质量折中曲线 [5]。受此评价方式启发，本文将 KGW fixed-delta 与 CA-KL epsilon 扫描都视为一组 operating points：散点表示冻结 test 输出的实测结果，平滑曲线仅用于展示同一方法族内部随水印强度变化的趋势，不作为新的实验观测。

表 3 汇总 test-500 $\times$ 3 seeds 的 14 个主工作点。每个点的检测、SimCSE 和 PPL 样本均来自相同的 500 个 prompt；括号内为 95% prompt-cluster bootstrap CI。

表 3: 独立测试集主工作点：standard KGW detector、SimCSE 与 corpus PPL

方法	参数	TPR@1%FPR	SimCSE	Corpus PPL
KGW	$\delta = 0.5$	30.20% [27.87,32.53]	0.7248 [0.7173,0.7320]	22.06 [21.17,23.00]
KGW	$\delta = 1.0$	92.27% [90.60,93.80]	0.6901 [0.6820,0.6982]	23.97 [22.99,24.97]
KGW	$\delta = 1.5$	98.73% [97.80,99.53]	0.6761 [0.6679,0.6842]	26.08 [25.06,27.11]
KGW	$\delta = 1.7$	98.93% [98.07,99.60]	0.6729 [0.6647,0.6815]	27.10 [26.01,28.29]
KGW	$\delta = 2.0$	99.33% [98.67,99.87]	0.6636 [0.6556,0.6716]	29.67 [28.52,30.86]
KGW	$\delta = 2.5$	99.53% [98.93,99.93]	0.6610 [0.6533,0.6688]	34.91 [33.58,36.37]
KGW	$\delta = 3.0$	99.73% [99.27,100]	0.6515 [0.6438,0.6592]	41.37 [39.67,43.01]
CA-KL	$\varepsilon = 0.02$	29.67% [27.27,32.20]	0.7218 [0.7143,0.7290]	22.97 [22.03,23.94]
CA-KL	$\varepsilon = 0.05$	70.47% [68.00,73.07]	0.7012 [0.6931,0.7088]	24.22 [23.27,25.26]
CA-KL	$\varepsilon = 0.10$	94.80% [93.40,96.07]	0.6875 [0.6791,0.6957]	25.25 [24.27,26.29]
CA-KL	$\varepsilon = 0.20$	98.80% [98.07,99.40]	0.6752 [0.6675,0.6830]	28.25 [27.18,29.32]
CA-KL	$\varepsilon = 0.30$	99.33% [98.73,99.80]	0.6692 [0.6611,0.6772]	30.10 [29.00,31.28]
CA-KL	$\varepsilon = 0.40$	99.60% [99.07,100]	0.6678 [0.6603,0.6755]	32.23 [31.04,33.45]
CA-KL	$\varepsilon = 0.50$	99.53% [98.93,99.93]	0.6566 [0.6484,0.6645]	34.14 [32.91,35.43]

在弱水印端，KGW $\delta = 0.5$ 与 CA-KL $\varepsilon = 0.02$ 的 TPR 接近（30.20% 对 29.67%），前者同时具有略高 SimCSE 和略低 PPL。在中等工作点，CA-KL $\varepsilon = 0.10$ 相比 KGW $\delta = 1.0$ 的 TPR 高 2.53 个百分点，但 SimCSE 低 0.0026、corpus PPL 高 1.28；相比 KGW $\delta = 1.5$ ，其质量更好但 TPR 低 3.93 个百分点。这说明 CA-KL 的改进不表现为单个点全面支配 KGW，而表现为用 ε 给出更细粒度、可解释的 token-specific 强度调节，使检测率可以沿连续预算曲线逐步提高。

图 3 聚焦 SimCSE ≤ 0.69 、TPR 介于 0.94–1.00 的高检测区，以观察饱和区附近的 detectability–semantic coherence 前沿。高检测率附近，CA-KL 的平滑趋势线与 KGW 曲线交错而非整体落后：例如 CA-KL $\varepsilon = 0.30$ 与 KGW $\delta = 2.0$ 的 TPR 均为 99.33%，但 SimCSE 分别为 0.6692 与 0.6636，前者高 0.0056；CA-KL $\varepsilon = 0.20$ 也在接近 98.8% TPR 时保持 0.6752 的 SimCSE。该结果与 Huo 等人强调的 token-specific 折中视角一致，即改进重点在于按位置调节嵌入强度，而不是把所有位置推向同一个固定偏置。




图 3: Test-500 $\times$ 3 seeds 的 SimCSE-TPR@1%FPR 高检测区。

图 4 展示完整 corpus PPL-TPR 轨迹。PPL 越低越好，TPR 越高越好。随着 KGW δ 或 CA-KL ϵ 增大，两条曲线先快速提升检测率，随后在 99% 附近饱和，而 PPL 仍继续增大。该图显示 CA-KL 的 PPL 曲线并不严格优于 KGW：在 99.33% TPR 处，CA-KL $\epsilon = 0.30$ 的 corpus PPL 为 30.10，略高于 KGW $\delta = 2.0$ 的 29.67；在更高检测区，CA-KL $\epsilon = 0.50$ 与 KGW $\delta = 2.5$ 的 TPR 均约为 99.5%，corpus PPL 分别为 34.14 与 34.91，CA-KL 略低。由此可见，CA-KL 的主要收益不是无条件降低 PPL，而是在可解释 KL 预算下形成可控的检测-质量曲线，并在部分高检测工作点改善语义一致性指标。




图 4: Test-500 $\times$ 3 seeds 的 corpus PPL-TPR@1%FPR 曲线。

综合 SimCSE 与 PPL, CA-KL 在当前协议下相对 KGW 的改进可以概括为两点。第一, 固定 δ 被逐 token KL 预算 ε 取代, 水印强度从经验偏置转化为可解释的分布约束, 参数扫描形成更连续的折中曲线。第二, 在部分高检测工作点, CA-KL 可以在相同或接近的 TPR 下获得更高 SimCSE, 例如 99.33% TPR 处相对 KGW $\delta = 2.0$ 的提升。与此同时, PPL 曲线与 KGW 仍有交错, bootstrap 区间也存在重叠, 因此本文不宣称 CA-KL 在 clean 条件下严格支配 KGW fixed-delta 包络, 而将其定位为一种更可控的 token-specific 水印强度分配方法。

5.3 完整方法与匹配检测

根据 validation 结果, CA-KL-CG 采用 $\varepsilon = 0.10$ 、candidate top-p=0.95 和 90% gate; 其 test 实际 gate pass rate 为 88.94%, 平均 candidate size 为 298.2。matched fixed-delta control 使用 $\delta = 1.5$ 和相同 candidate/gate, 实际 gate pass rate 为 89.01%。表 4 展示 clean test 结果。

表 4: 完整方法的 standard 与 matched detector 结果 (目标 FPR 1%, 实际 human FPR 均为 0.6%)

生成方法	Detector	TPR [95% CI]	SimCSE	Corpus PPL
CA-KL-CG	Standard KGW	86.40% [84.40,88.47]	0.6897	21.27
CA-KL-CG	Matched weighted-global	97.80% [96.80,98.67]	0.6897	21.27
CA-KL-CG	Matched weighted-winmax	89.33% [87.67,91.00]	0.6897	21.27
KGW-CG $\delta = 1.5$	Standard KGW	97.73% [96.67,98.67]	0.6820	20.66
KGW-CG $\delta = 1.5$	Matched weighted-global	98.80% [97.93,99.53]	0.6820	20.66
KGW-CG $\delta = 1.5$	Matched weighted-winmax	98.60% [97.60,99.40]	0.6820	20.66

CA-KL-CG 的 standard TPR 为 86.40%, 低于 CA-KL base $\varepsilon = 0.10$ 的 94.80%。由于 standard detector 未重建 candidate 支持集与 gate, 该差异反映的是生成-检测配置失配, 而非水印证据的完全消失。matched weighted-global 达到 97.80%, 比 standard 高 11.40 个百分点, 验证了检测配置匹配的必要性。Weighted-WinMax 在 clean 全文上的 TPR 低于 global; 独立阈值校准控制了窗口搜索的多重比较效应, 说明局部窗口聚合在全文水印场景中不必然提高检测功效。

与 matched KGW-CG 对照相比, CA-KL-CG 的 SimCSE 高 0.0077, 但 TPR 低 1.0 个百分点、corpus PPL 高 0.61, 因此不存在单方面支配。该对照将完整系统的效应分解为动态 KL、candidate/gate 和 detector 三部分, 避免将检测器增益直接归因于生成算法。

6 总结

本文从 KGW 复现出发, 研究逐 token KL 约束水印及其 candidate/gate 扩展。实验采用结构化数据划分、全词表 greenlist、精确 continuation token 计分、检测器配置配对与 held-out 阈值校准; validation/test 各 500 条固定数据、三个 test seeds 和完整参数网格共同保证结果可比较。

test-500 $\times$ 3 seeds 表明, CA-KL $\varepsilon = 0.10$ 达到 94.80% TPR@1%FPR、0.6875 SimCSE 和 25.25 corpus PPL。该点与 KGW 包络接近, 但不足以支持严格 Pareto 改进。完整方法 CA-KL-CG 在 matched weighted-global detector 下达到 97.80% TPR, 明显高于其 standard 诊断值 86.40%, 证明匹配检测是 candidate/gate 系统不可缺少的组成部分。

因此, 实验结果不支持 CA-KL 在 clean 条件下全面优于 KGW, 但支持以下方法贡献: 逐 token KL 预算把水印强度转化为具有明确分布意义的约束; candidate/gate 与 matched detector 构成了清晰的联合生成-检测系统。上述结论由独立测试集上的检测率、SimCSE 与 corpus PPL 共同支持。

7 实验分工

施煌: 负责 KGW 原论文阅读、官方仓库复现、C4 数据流程核对, 以及报告中方法背景与复现部分的整理。

祖裕柏: 负责本文改进水印生成端的主要实现与实验执行。具体包括在 KGW logits processor 基础上实现 CA-KL 逐位置 KL 预算求解, 将固定 δ 改为按当前位置分布自适应选择的 δ_t ; 设计并实现

candidate-aware greenlist, 使水印划分限制在当前 top-p 候选集合内; 实现基于 entropy/top-1 条件的 confidence gate, 控制哪些生成位置参与嵌入; 编写批量生成脚本, 完成 KGW fixed-delta、CA-KL epsilon 网格、candidate-only、gate-only 与 candidate+gate 等方法的 validation 参数扫描和 test 集独立生成, 并整理生成结果、运行日志与实验配置。

黄镇邦: 负责检测端、离线评测与结果分析的主要工作。具体包括实现 standard KGW detector 以及与 candidate/gate 配置一致的 matched weighted-global、matched weighted-winmax detector; 设计 validation human completions 上的低 FPR 阈值校准流程, 并在 test human completions 上核对实际误报率; 完成 continuation-only corpus PPL 与 prompt/seed 配对 SimCSE 评测, 保证质量指标只作用于生成 continuation; 编写 prompt-cluster bootstrap 统计脚本, 估计 TPR、SimCSE 与 PPL 的 95% 置信区间; 绘制检测率-语义一致性、检测率-PPL 折中曲线和完整方法对比表, 并负责报告中实验结果、统计解释和结论边界的撰写。

参考文献

- [1] J. Kirchenbauer, J. Geiping, Y. Wen, J. Katz, I. Miers, and T. Goldstein, “A watermark for large language models,” in *Proceedings of the 40th International Conference on Machine Learning*, vol. 202 of *Proceedings of Machine Learning Research*, pp. 17061–17084, PMLR, 2023.
- [2] J. Kirchenbauer, J. Geiping, Y. Wen, M. Shu, K. Saifullah, K. Kong, K. Fernando, A. Saha, M. Goldblum, and T. Goldstein, “On the reliability of watermarks for large language models,” in *International Conference on Learning Representations*, 2024.
- [3] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, “Exploring the limits of transfer learning with a unified text-to-text transformer,” *Journal of Machine Learning Research*, vol. 21, no. 140, pp. 1–67, 2020.
- [4] S. Zhang, S. Roller, N. Goyal, M. Artetxe, M. Chen, S. Chen, C. Dewan, M. Diab, X. Li, X. V. Lin, T. Mihaylov, M. Ott, S. Shleifer, K. Shuster, D. Simig, P. S. Koura, A. Sridhar, T. Wang, and L. Zettlemoyer, “OPT: Open pre-trained transformer language models,” 2022.
- [5] M. Huo, S. A. Somayajula, Y. Liang, R. Zhang, F. Koushanfar, and P. Xie, “Token-specific watermarking with enhanced detectability and semantic coherence for large language models,” in *Proceedings of the 41st International Conference on Machine Learning*, vol. 235 of *Proceedings of Machine Learning Research*, pp. 20746–20767, PMLR, 2024.