



中山大學

SUN YAT-SEN UNIVERSITY

信息安全技术课程期末报告

大语言模型生成文本水印技术的 复现、改进与实验评估

基于 KGW 统计水印方法的检测率与文本质量分析

学生姓名：施煌，祖裕柏，黄镇邦

学号：23336204，23344188，23342035

院系：计算机学院

2026 年 7 月

摘要

大语言模型生成文本的可追溯性是内容安全与信息治理中的重要问题。统计水印方法通过在生成阶段引入可检测的概率偏置,使检测端能够在不知道原始采样轨迹的情况下判断文本来源。本文以 Kirchenbauer 等人提出的 KGW 方法为基线,完成官方链路复现,并进一步研究逐位置 KL 约束的水印生成方式。该方法在每个生成位置根据原始词分布自适应求解水印偏置,使分布扰动受到 $D_{\text{KL}}(Q_t \| P_t) \leq \varepsilon$ 的显式约束;在此基础上,本文结合候选集合约束、置信门控和匹配检测器,构建生成端与检测端一致的文本水印流程。

实验基于 C4/realnewslike 数据构造互不重叠的参数选择集和独立测试集,在 OPT-1.3B 模型上生成定长 continuation,并以低误报率阈值校准、语义相似度、困惑度和 bootstrap 置信区间综合评价检测能力与文本质量。结果表明,逐位置 KL 预算能够形成连续可调的检测-质量折中:当 ε 从 0.02 增至 0.50 时,TPR@1%FPR 由 29.67% 提升至 99.53%,SimCSE 由 0.7218 降至 0.6566,corpus PPL 由 22.97 增至 34.14。在 $\varepsilon = 0.10$ 的代表性工作点上,该方法达到 94.80% TPR@1%FPR、0.6875 SimCSE 和 25.25 corpus PPL,与 KGW 固定偏置方法形成接近但不完全支配的性能关系。

进一步实验显示,候选集合约束与置信门控会改变有效水印位置和统计权重,因此检测器必须与生成机制保持一致。对于完整方法,标准 KGW 检测器得到 86.40% TPR,而匹配的 weighted-global 检测器达到 97.80% TPR,说明检测配置对统计功效具有关键影响。总体而言,本文验证了 KGW 文本水印的基本有效性,给出了逐位置 KL 预算下水印强度、检测率与文本质量之间的量化关系,并表明匹配检测是改进型水印系统中不可忽略的组成部分。

关键词: 大语言模型; 文本水印; KGW; KL 散度; 匹配检测; 低误报率校准

目录

1	引言	1
2	KGW 方法与复现	1
2.1	Seeded greenlist 与固定偏置	1
2.2	官方链路复现	1
3	逐位置 KL 约束与匹配检测	2
3.1	逐位置 KL 预算	2
3.2	候选集合与置信门控	3
3.3	匹配检测器	3
4	实验设计	3
4.1	数据集与任务构造	3
4.2	模型与参数设置	3
4.3	实验步骤	4
4.4	评价指标与统计方法	4
4.5	代码运行证明	4
5	实验结果	5
5.1	Validation 集上的参数选择	5
5.2	独立测试集上的 KGW 与 CA-KL	6
5.3	完整方法与匹配检测	8
6	总结	8
7	实验分工	9

1 引言

生成式大语言模型已经广泛进入写作、问答、教育和内容平台。模型文本与人工文本在表面形式上日益接近，使内容归属、批量生成识别和后续审计变得困难。文本水印的目标是在不增加可见标记的情况下，通过受密钥控制的生成概率偏置，在文本中留下可重复检验的统计证据。与训练一个通用 AI 文本分类器相比，生成式水印直接利用模型端密钥和生成过程，检测假设更明确，也更适合回答“该文本是否由某个受控模型生成”。

本文以 ICML 2023 的 KGW 水印为复现对象 [1]。原方法在每一步将词表按密钥划分为 greenlist 与 redlist，并给 greenlist logits 加固定偏置。固定偏置的优势是实现和统计简单，但同一个 δ 在不同 next-token 分布上对应不同的真实扰动：模型非常确定时，推动其转向 green token 的代价可能很大；候选较多时，相同偏置又可能较温和。由此，本文研究逐位置 KL 预算能否比固定 δ 提供更可解释的检测-质量折中。

本文的主要工作如下：

1. 完成 KGW 官方生成-检测链路复现，并保留其 seeded greenlist 与标准 z-score 作为共同基线；
2. 建立结构化数据、全词表 greenlist、精确 PPL/SimCSE 计分、detector pairing 与 held-out calibration 组成的可复现实验流程；
3. 在独立测试集和三组随机种子上比较 7 个 KGW 固定偏置工作点与 7 个 CA-KL 预算工作点，并报告独立误报率、主要质量指标和 prompt-cluster bootstrap 区间；
4. 对 validation 选定的 CA-KL-CG 与 matched KGW-CG 对照分别使用 standard、weighted-global 和 weighted-winmax 检测，分析生成逻辑与检测器匹配的作用。

2 KGW 方法与复现

2.1 Seeded greenlist 与固定偏置

设基础语言模型在位置 t 的条件分布为 $P_t(v) = P(v | x_{<t})$ ，词表为 $\mathcal{V}$ 。KGW 用密钥和前缀 $x_{<t}$ 产生伪随机种子，将 $\gamma|\mathcal{V}|$ 个 token 划入 greenlist G_t 。若原 logits 为 $l_t(v)$ ，固定偏置生成分布使用

$$l'_t(v) = l_t(v) + \delta \mathbf{1}[v \in G_t].$$

检测端使用同一密钥逐位置重建 G_t 。对长度为 T 的待测文本，若观测到 N_G 个 green token，则标准 KGW 统计量为

$$z = \frac{N_G - \gamma T}{\sqrt{T\gamma(1-\gamma)}}.$$

无水印零假设下，green token 比例应接近 γ ；显著偏高的 z 支持水印假设。本文始终令 $\gamma = 0.25$ ，并对 standard detector 的阈值在 validation human completions 上独立校准，而不是把固定的 $z > 4$ 当作正式低 FPR 结论。可靠性研究同样强调阈值校准、误报率与文本长度的重要性 [2]。

2.2 官方链路复现

复现阶段按官方仓库完成最小模型和 OPT 模型的生成-检测链路验证，并处理新版 Gradio 的接口兼容问题。图 1 展示了一次典型 Demo：无水印文本的 green fraction 为 22.2%、 $z = -0.638$ ；带水印文本的 green fraction 为 70.4%、 $z = 10.4$ 。该结果确认密钥播种、greenlist 重建、logits 偏置与检测统计量能够端到端工作。

Generate																			
Output Without Watermark native to the Caribbean Sea, the Gulf of Mexico, and the Pacific Northwest. It is also known as the 'terrapin of the sea' by its trademark red, blue, and yellow markings. It is rare to see a turtle within the range of the terrapin.[10] The species is often called terrapin because it is so widely seen in the Caribbean Sea with its white markings. The turtles have a distinctive red, green, or yellow coloration, and may	<table> <tr><th>Metric</th><th>Value</th></tr> <tr><td>Tokens Counted (T)</td><td>99</td></tr> <tr><td># Tokens in Greenlist</td><td>22</td></tr> <tr><td>Fraction of T in Greenlist</td><td>22.2%</td></tr> <tr><td>z-score</td><td>-0.638</td></tr> <tr><td>p value</td><td>0.738</td></tr> <tr><td>z-score Threshold</td><td>4.0</td></tr> <tr><td>Prediction</td><td>Human/Unwatermarked</td></tr> </table>	Metric	Value	Tokens Counted (T)	99	# Tokens in Greenlist	22	Fraction of T in Greenlist	22.2%	z-score	-0.638	p value	0.738	z-score Threshold	4.0	Prediction	Human/Unwatermarked		
Metric	Value																		
Tokens Counted (T)	99																		
# Tokens in Greenlist	22																		
Fraction of T in Greenlist	22.2%																		
z-score	-0.638																		
p value	0.738																		
z-score Threshold	4.0																		
Prediction	Human/Unwatermarked																		
Output With Watermark native of the brackish-water portions of the Caribbean, and the northern and eastern Caribbean islands (notably Bermuda, Colombia and the Bahamas). [10] The blackhead is large in its body and is white. The tail is white-colored and the long tail feathers light brown, although its body color can vary significantly with the coloration of the skin. The tail feathers have a white-colored color, the body color can vary significantly with the coloration of the skin, and the	<table> <tr><th>Metric</th><th>Value</th></tr> <tr><td>Tokens Counted (T)</td><td>98</td></tr> <tr><td># Tokens in Greenlist</td><td>69</td></tr> <tr><td>Fraction of T in Greenlist</td><td>70.4%</td></tr> <tr><td>z-score</td><td>10.4</td></tr> <tr><td>p value</td><td>1.51e-25</td></tr> <tr><td>z-score Threshold</td><td>4.0</td></tr> <tr><td>Prediction</td><td>Watermarked</td></tr> <tr><td>Confidence</td><td>100.000%</td></tr> </table>	Metric	Value	Tokens Counted (T)	98	# Tokens in Greenlist	69	Fraction of T in Greenlist	70.4%	z-score	10.4	p value	1.51e-25	z-score Threshold	4.0	Prediction	Watermarked	Confidence	100.000%
Metric	Value																		
Tokens Counted (T)	98																		
# Tokens in Greenlist	69																		
Fraction of T in Greenlist	70.4%																		
z-score	10.4																		
p value	1.51e-25																		
z-score Threshold	4.0																		
Prediction	Watermarked																		
Confidence	100.000%																		
Advanced Settings																			

图 1: KGW 官方 Demo 的生成与检测复现。

3 逐位置 KL 约束与匹配检测

KGW 水印通过固定 logit 偏置提高 green token 的采样概率，其检测统计量简洁、可复现性强，但固定 δ 并不直接对应固定的分布扰动。对同一个 δ ，当基础模型在当前位置的分布更尖锐时，水印需要以更大的概率改变换取 green token 增益；当分布更平坦或候选 token 较多时，相同偏置造成的改变又相对温和。因此，本文将水印强度从固定偏置改写为逐位置 KL 预算，使每个生成位置的采样分布变化都由同一个可解释的上界控制，并进一步结合候选集合、置信门控和匹配检测器，使嵌入端与检测端围绕同一组条件分布完成统计判断。

在生成位置 t ，基础语言模型首先给出条件分布 $P_t(v) = P(v | x_{<t})$ ；随后密钥和当前前缀共同确定可嵌入 token 的 greenlist，并由候选集合与置信门控决定当前位置是否施加水印。若该位置被选为可嵌入位置，算法求解满足逐 token KL 约束的最大偏置 δ_t ，据此得到水印采样分布 Q_t 并生成下一个 token；若当前位置未通过门控，则保持原分布采样。检测时，检测器在相同密钥、相同基础模型和相同上下文下重建候选集合、greenlist、门控状态及其概率质量，并将每个位置的证据聚合为标准或加权统计量，最后用 validation human completions 校准的阈值判断文本是否含有水印。

3.1 逐位置 KL 预算

设原分布落在 greenlist 上的概率质量为

$$p_{G,t} = \sum_{v \in G_t} P_t(v).$$

给 green token 加偏置 δ 后，归一化常数与新 green mass 分别为

$$Z_t(\delta) = 1 + p_{G,t}(e^\delta - 1), \quad q_{G,t}(\delta) = \frac{e^\delta p_{G,t}}{Z_t(\delta)}.$$

加水印分布 $Q_{t,\delta}$ 相对原分布的正向 KL 为

$$D_{\text{KL}}(Q_{t,\delta} \| P_t) = \delta q_{G,t}(\delta) - \log Z_t(\delta).$$

CA-KL 在每个位置通过二分搜索选择

$$\delta_t = \max\{\delta \in [0, \delta_{\max}] : D_{\text{KL}}(Q_{t,\delta} \| P_t) \leq \varepsilon\},$$

其中 $\delta_{\max} = 3.0$ ， ε 是逐 token 上限，而非整段文本的总预算。该约束直接限制当前采样分布相对基础分布的改变幅度，使水印强度具有明确的分布意义。

CA-KL 的闭式 KL 定义在水印处理器接收的完整 softmax 分布上。实验采用 temperature 1.0、top-k 0 和 top-p 1.0，使处理器输出的 $Q_{t,\delta}$ 直接构成实际采样分布，避免后续温度缩放或候选截断改变概率支持集。在实现中，词表空间 $\mathcal{V}$ 以模型输出层定义，从而覆盖全部可采样 token；生成端与检测端在同一词表空间内执行密钥划分，保证 greenlist 重建的一致性。

3.2 候选集合与置信门控

仅在完整词表上划分 greenlist 会把一部分几乎不可能被采样的 token 纳入水印集合，导致有效证据与实际采样空间之间存在偏差。为此，本文引入 candidate-aware greenlist。令 C_t 为按 $P_t(v)$ 降序排列后、累计概率首次达到 candidate top-p 的最小 token 集合，算法只在 C_t 内依据密钥划分 green token，并在候选集合外保持原始采样概率。该设计使水印嵌入集中于模型当前真正可能选择的候选空间，减少低概率尾部 token 对统计证据的干扰。

置信门控用于进一步选择适合嵌入水印的位置。设 $g_t \in \{0, 1\}$ 表示当前位置是否满足 entropy/top-1 条件：当基础分布过于确定或不满足预设置信条件时，算法令 $g_t = 0$ 并取 $\delta_t = 0$ ；当 $g_t = 1$ 时，才在候选集合内求解逐位置 KL 约束下的偏置。候选集合决定水印划分的有效支持集，置信门控决定哪些位置参与嵌入，二者共同构成本文完整方法 CA-KL-CG。

3.3 匹配检测器

当生成端使用候选集合或置信门控后，传统 KGW 检测器若仍按完整词表、全位置统计 green token，会与实际嵌入机制不完全一致。因此，本文使用 matched detector 作为完整方法的主要检测器：检测端逐位置重放基础模型分布，并在相同密钥下重建 C_t 、 G_t 、 g_t 和 $p_{G,t}$ 。对于未通过门控的位置，检测器不将其作为有效水印证据；对于通过门控的位置，则按照重建后的候选空间计算 green token 偏离期望的程度。

一种一般化的 weighted z-score 可写为

$$z_w = \frac{\sum_t w_t (1[x_t \in G_t] - p_{G,t})}{\sqrt{\sum_t w_t^2 p_{G,t} (1 - p_{G,t})}},$$

其中 w_t 由模型分布和可嵌入性决定。Weighted-global 在全文范围内聚合证据；Weighted-WinMax 在多个滑动窗口上计算 z_w 并取最大值。由于窗口搜索会引入多重比较效应，Weighted-WinMax 的阈值在 validation 集上独立校准，不与 standard 或 global 检测器共享阈值。本文的评测范围为未攻击生成场景，WinMax 用于比较不同检测证据聚合方式的效果。

4 实验设计

4.1 数据集与任务构造

数据来自 C4/realnewslike [3]。每条 source 经 OPT tokenizer 分词后保留 500–1000 token，末尾 200 token 作为 human completion，其前部保留 300–800 token 作为 prompt。数据以稳定 source ID 去重，并划分为互不重叠的 validation 与 test，各包含 500 条记录。validation 用于参数选择和检测阈值校准，test 用于最终性能评测。

4.2 模型与参数设置

生成模型为 facebook/opt-1.3b [4]，revision 为 3f5c25d0bc631cb57ac65913f76e22c2dfb61d62，FP16 推理。所有方法共享同一 prompt、生成长度、采样参数和 per-prompt 稳定 seed，配置见表 1。

表 1: 实验模型、采样参数与工作点

项目	冻结值
数据	C4/realnewslike; validation 500, test 500
Prompt / human / generation	300–800 / 200 / 200 OPT tokens
Temperature / top-k / top-p	1.0 / 0 / 1.0
Greenlist 比例 / seeding	$\gamma = 0.25$ / <code>simple_1</code>
KGW 网格	$\delta \in \{0.5, 1.0, 1.5, 1.7, 2.0, 2.5, 3.0\}$
CA-KL 网格	$\varepsilon \in \{0.02, 0.05, 0.10, 0.20, 0.30, 0.40, 0.50\}$, $\delta_{\max} = 3$
完整方法	$\varepsilon = 0.10$, candidate top-p=0.95, gate target=90%
Matched control	KGW $\delta = 1.5$, 相同 candidate 与 gate
Test base seeds	1234, 2345, 3456

4.3 实验步骤

实验按照以下四个步骤完成:

1. 在小规模样本上验证 KGW、CA-KL 与 matched detector 的实现一致性, 包括固定生成长度、 $\varepsilon = 0$ 与 No-Watermark 等价、逐步 KL 约束、PPL continuation 边界以及 SimCSE 一一配对;
2. 在 validation 集上扫描 KGW 固定偏置与 CA-KL 预算网格, 并完成 candidate-only、gate-only 和 candidate+gate 消融, 根据预设规则选择完整方法参数;
3. 固定模型、采样参数、方法工作点、检测器配置和随机种子, 在独立测试集的 500 条 prompt 上以三组基础随机种子生成全部比较文本;
4. 对冻结的 test 输出统一计算 standard/matched detector、corpus PPL 与 SimCSE, 并使用 2,000 次 prompt-cluster bootstrap 估计 95% 置信区间。

4.4 评价指标与统计方法

主检测指标为 TPR@1%FPR。每个 detector 均在 validation human completions 上以有限样本次序统计量确定阈值; test human completions 用于测量实际 FPR, test watermarked completions 用于测量 TPR。No-Watermark 模型文本的 model-null FPR 作为辅助统计量单独报告, human FPR 作为正式误报口径。standard KGW 的 1% 目标阈值为 $z > 2.4495$; test human FPR 为 0.6% (95% CI 0–1.4%), No-Watermark model-null FPR 为 0.8% (0.4–1.27%)。

主语义指标为 continuation-only SimCSE cosine: 对相同 prompt 和 seed, 将水印 completion 与 No-Watermark completion 一一配对, 使用 `princeton-nlp/sup-simcse-roberta-base` 自己的 tokenizer 和 pooler embedding。主分布质量指标为 continuation corpus PPL:

$$\text{PPL}_{\text{corpus}} = \exp\left(\frac{\sum_i \text{NLL}_i}{\sum_i T_i}\right),$$

只在生成 continuation 的精确 token IDs 上计分。图中的 mean row PPL 用于直观展示每条文本分布, 主表使用 corpus PPL。

95% CI 使用固定 calibration threshold 下的 2,000 次 prompt-cluster bootstrap。cluster 单位是 `prompt_id`, 同一 prompt 的三个 generation seeds 一起重采样, 因而没有把 1,500 条重复测量误当成完全独立样本。区间反映 test prompt 抽样不确定性, 不包含 validation threshold 的再次抽样不确定性。

4.5 代码运行证明

课程要求报告中包含代码运行效果截图。图 2 展示批量实验脚本在服务器端完成多方法生成、结果文件保存、PPL 计算与校准指标输出的终端日志, 其中包含最后一批 prompts 的处理进度以及结果 CSV、summary 与 calibrated metrics 的写入路径, 可作为本文实验代码完整运行的证明。

```

inform > course_project > outputs > additional > paper_controlled > paper_controlled_run.log
2974 [Prompt 495/499] CA-KL + Candidate Greenlist + Weighted/WinMax
2975 [Prompt 496/499] Generating baseline outputs...
2976 [Prompt 496/499] Fixed delta=2.0
2977 [Prompt 496/499] Adaptive delta
2978 [Prompt 496/499] CA-KL
2979 [Prompt 496/499] CA-KL + Candidate Greenlist
2980 [Prompt 496/499] CA-KL + Candidate Greenlist + Weighted/WinMax
2981 [Prompt 497/499] Generating baseline outputs...
2982 [Prompt 497/499] Fixed delta=2.0
2983 [Prompt 497/499] Adaptive delta
2984 [Prompt 497/499] CA-KL
2985 [Prompt 497/499] CA-KL + Candidate Greenlist
2986 [Prompt 497/499] CA-KL + Candidate Greenlist + Weighted/WinMax
2987 [Prompt 498/499] Generating baseline outputs...
2988 [Prompt 498/499] Fixed delta=2.0
2989 [Prompt 498/499] Adaptive delta
2990 [Prompt 498/499] CA-KL
2991 [Prompt 498/499] CA-KL + Candidate Greenlist
2992 [Prompt 498/499] CA-KL + Candidate Greenlist + Weighted/WinMax
2993 [Prompt 499/499] Generating baseline outputs...
2994 [Prompt 499/499] Fixed delta=2.0
2995 [Prompt 499/499] Adaptive delta
2996 [Prompt 499/499] CA-KL
2997 [Prompt 499/499] CA-KL + Candidate Greenlist
2998 [Prompt 499/499] CA-KL + Candidate Greenlist + Weighted/WinMax
2999 Saved 3493 rows to /home/zyb/inform/course_project/outputs/additional/paper_controlled/opt13b_paper_c4_500_t200_improved_fp32_results.csv
3000 Saved summary to /home/zyb/inform/course_project/outputs/additional/paper_controlled/opt13b_paper_c4_500_t200_improved_fp32_summary.md
3001
3002 Loading weights: 0%| | 0/517 [00:00<?, ?it/s]
3003 Loading weights: 100%| | 517/517 [00:00<00:00, 51785.24it/s]
3004 Saved PPL rows to /home/zyb/inform/course_project/outputs/additional/paper_controlled/opt13b_paper_c4_500_t200_improved_fp32_ppl_results.csv
3005 Saved PPL summary to /home/zyb/inform/course_project/outputs/additional/paper_controlled/opt13b_paper_c4_500_t200_improved_fp32_ppl_summary.md
3006 Saved independently calibrated metrics to /home/zyb/inform/course_project/outputs/additional/paper_controlled/calibration
3007 [done] Results: /home/zyb/inform/course_project/outputs/additional/paper_controlled/opt13b_paper_c4_500_t200_improved_fp32_results.csv
3008

```

图 2: 代码运行效果截图: 批量生成、PPL 计算与检测校准输出。

5 实验结果

5.1 Validation 集上的参数选择

Validation 集上的完整网格表明, KGW 和 CA-KL 均覆盖从约 30% TPR 到接近饱和的弱、中、强水印区间。CA-KL $\epsilon = 0.10$ 取得 97.6% standard TPR@1%FPR, SimCSE 为 0.6790, 位于 95–98% 的目标检测率范围内, 因而被选为候选集合与置信门控消融的基础工作点; 其余 ϵ 取值用于构建完整参数曲线。

Candidate-only 的 top-p=0.90、0.95、0.99 在 matched weighted-global detector 下的 validation TPR 分别为 99.0%、99.2%、98.8%, 对应 SimCSE 为 0.6842、0.6853、0.6781; 因此选择 0.95。Gate-only 依据 No-Watermark validation 分布构造约 90%、75%、50% 三种覆盖率。最终 candidate+gate 对比见表 2, 按“先最大化未攻击场景下的 weighted-global TPR@1%FPR, 再比较 SimCSE”的规则选中 90% gate。

表 2: Validation 集上 candidate top-p=0.95 的 gate 参数选择

目标 gate pass	实际含义	Weighted-global TPR	SimCSE	Mean row PPL
90%	弱 gate	99.0%	0.6852	26.086
75%	中 gate	98.8%	0.6892	25.592
50%	强 gate	94.2%	0.6956	25.230

90% gate 的冻结阈值为 normalized entropy $H_{\min} = 0.0067067$ 、top-1 probability $p_{\max} = 0.9793311$ 。同时冻结匹配的固定偏置对照: KGW $\delta = 1.5$ 加相同 candidate top-p 与 gate。这样可区分动态 KL 与 candidate/gate、detector 本身的贡献。

5.2 独立测试集上的 KGW 与 CA-KL

Huo 等人的逐 token 水印研究将可检测性与语义一致性作为联合优化目标，强调水印方法不能只用单一强度下的检测率判断，而应观察不同水印强度形成的检测–质量折中曲线 [5]。受此评价方式启发，本文将 KGW 固定偏置与 CA-KL 预算扫描都视为一组工作点：散点表示独立测试集输出的实测结果，平滑曲线仅用于展示同一方法族内部随水印强度变化的趋势，不作为新的实验观测。

表 3 汇总独立测试集三组随机种子下的 14 个主工作点。每个点的检测、SimCSE 和 PPL 样本均来自相同的 500 个 prompt；括号内为 95% prompt-cluster bootstrap CI。

表 3: 独立测试集主工作点：standard KGW detector、SimCSE 与 corpus PPL

方法	参数	TPR@1%FPR	SimCSE	Corpus PPL
KGW	$\delta = 0.5$	30.20% [27.87,32.53]	0.7248 [0.7173,0.7320]	22.06 [21.17,23.00]
KGW	$\delta = 1.0$	92.27% [90.60,93.80]	0.6901 [0.6820,0.6982]	23.97 [22.99,24.97]
KGW	$\delta = 1.5$	98.73% [97.80,99.53]	0.6761 [0.6679,0.6842]	26.08 [25.06,27.11]
KGW	$\delta = 1.7$	98.93% [98.07,99.60]	0.6729 [0.6647,0.6815]	27.10 [26.01,28.29]
KGW	$\delta = 2.0$	99.33% [98.67,99.87]	0.6636 [0.6556,0.6716]	29.67 [28.52,30.86]
KGW	$\delta = 2.5$	99.53% [98.93,99.93]	0.6610 [0.6533,0.6688]	34.91 [33.58,36.37]
KGW	$\delta = 3.0$	99.73% [99.27,100]	0.6515 [0.6438,0.6592]	41.37 [39.67,43.01]
CA-KL	$\varepsilon = 0.02$	29.67% [27.27,32.20]	0.7218 [0.7143,0.7290]	22.97 [22.03,23.94]
CA-KL	$\varepsilon = 0.05$	70.47% [68.00,73.07]	0.7012 [0.6931,0.7088]	24.22 [23.27,25.26]
CA-KL	$\varepsilon = 0.10$	94.80% [93.40,96.07]	0.6875 [0.6791,0.6957]	25.25 [24.27,26.29]
CA-KL	$\varepsilon = 0.20$	98.80% [98.07,99.40]	0.6752 [0.6675,0.6830]	28.25 [27.18,29.32]
CA-KL	$\varepsilon = 0.30$	99.33% [98.73,99.80]	0.6692 [0.6611,0.6772]	30.10 [29.00,31.28]
CA-KL	$\varepsilon = 0.40$	99.60% [99.07,100]	0.6678 [0.6603,0.6755]	32.23 [31.04,33.45]
CA-KL	$\varepsilon = 0.50$	99.53% [98.93,99.93]	0.6566 [0.6484,0.6645]	34.14 [32.91,35.43]

在弱水印端，KGW $\delta = 0.5$ 与 CA-KL $\varepsilon = 0.02$ 的 TPR 接近（30.20% 对 29.67%），前者同时具有略高 SimCSE 和略低 PPL。在中等工作点，CA-KL $\varepsilon = 0.10$ 相比 KGW $\delta = 1.0$ 的 TPR 高 2.53 个百分点，但 SimCSE 低 0.0026、corpus PPL 高 1.28；相比 KGW $\delta = 1.5$ ，其质量更好但 TPR 低 3.93 个百分点。这说明 CA-KL 的改进不表现为单个点全面支配 KGW，而表现为用 ε 给出更细粒度、可解释的逐位置强度调节，使检测率可以沿连续预算曲线逐步提高。

图 3 聚焦 $\text{SimCSE} \leq 0.69$ 、TPR 介于 0.94–1.00 的高检测区，以观察饱和区附近的检测率–语义一致性前沿。高检测率附近，CA-KL 的平滑趋势线与 KGW 曲线交错而非整体落后：例如 CA-KL $\varepsilon = 0.30$ 与 KGW $\delta = 2.0$ 的 TPR 均为 99.33%，但 SimCSE 分别为 0.6692 与 0.6636，前者高 0.0056；CA-KL $\varepsilon = 0.20$ 也在接近 98.8% TPR 时保持 0.6752 的 SimCSE。该结果与 Huo 等人强调的逐 token 折中视角一致，即改进重点在于按位置调节嵌入强度，而不是把所有位置推向同一个固定偏置。




图 3: Test-500 $\times$ 3 seeds 的 SimCSE-TPR@1%FPR 高检测区。

图 4 展示完整 corpus PPL-TPR 轨迹。PPL 越低越好，TPR 越高越好。随着 KGW δ 或 CA-KL ϵ 增大，两条曲线先快速提升检测率，随后在 99% 附近饱和，而 PPL 仍继续增大。该图显示 CA-KL 的 PPL 曲线并不严格优于 KGW：在 99.33% TPR 处，CA-KL $\epsilon = 0.30$ 的 corpus PPL 为 30.10，略高于 KGW $\delta = 2.0$ 的 29.67；在更高检测区，CA-KL $\epsilon = 0.50$ 与 KGW $\delta = 2.5$ 的 TPR 均约为 99.5%，corpus PPL 分别为 34.14 与 34.91，CA-KL 略低。由此可见，CA-KL 的主要收益不是无条件降低 PPL，而是在可解释 KL 预算下形成可控的检测-质量曲线，并在部分高检测工作点改善语义一致性指标。




图 4: Test-500 $\times$ 3 seeds 的 corpus PPL-TPR@1%FPR 曲线。

综合 SimCSE 与 PPL, CA-KL 在当前协议下相对 KGW 的改进可以概括为两点。第一, 固定 δ 被逐 token KL 预算 ε 取代, 水印强度从经验偏置转化为可解释的分布约束, 参数扫描形成更连续的折中曲线。第二, 在部分高检测工作点, CA-KL 可以在相同或接近的 TPR 下获得更高 SimCSE, 例如 99.33% TPR 处相对 KGW $\delta = 2.0$ 的提升。与此同时, PPL 曲线与 KGW 仍有交错, bootstrap 区间也存在重叠, 因此本文不宣称 CA-KL 在未攻击条件下严格优于 KGW 固定偏置包络, 而将其定位为一种更可控的逐 token 水印强度分配方法。

5.3 完整方法与匹配检测

根据 validation 结果, CA-KL-CG 采用 $\varepsilon = 0.10$ 、candidate top-p=0.95 和 90% gate; 其独立测试集实际 gate pass rate 为 88.94%, 平均 candidate size 为 298.2。匹配的固定偏置对照使用 $\delta = 1.5$ 和相同候选集合/门控配置, 实际 gate pass rate 为 89.01%。表 4 展示未攻击测试集结果。

表 4: 完整方法的 standard 与 matched detector 结果 (目标 FPR 1%, 实际 human FPR 均为 0.6%)

生成方法	Detector	TPR [95% CI]	SimCSE	Corpus PPL
CA-KL-CG	Standard KGW	86.40% [84.40,88.47]	0.6897	21.27
CA-KL-CG	Matched weighted-global	97.80% [96.80,98.67]	0.6897	21.27
CA-KL-CG	Matched weighted-winmax	89.33% [87.67,91.00]	0.6897	21.27
KGW-CG $\delta = 1.5$	Standard KGW	97.73% [96.67,98.67]	0.6820	20.66
KGW-CG $\delta = 1.5$	Matched weighted-global	98.80% [97.93,99.53]	0.6820	20.66
KGW-CG $\delta = 1.5$	Matched weighted-winmax	98.60% [97.60,99.40]	0.6820	20.66

CA-KL-CG 的 standard TPR 为 86.40%, 低于 CA-KL base $\varepsilon = 0.10$ 的 94.80%。由于 standard detector 未重建 candidate 支持集与 gate, 该差异反映的是生成-检测配置失配, 而非水印证据的完全消失。matched weighted-global 达到 97.80%, 比 standard 高 11.40 个百分点, 验证了检测配置匹配的必要性。Weighted-WinMax 在未攻击全文上的 TPR 低于 global; 独立阈值校准控制了窗口搜索的多重比较效应, 说明局部窗口聚合在全文水印场景中不必然提高检测功效。

与 matched KGW-CG 对照相比, CA-KL-CG 的 SimCSE 高 0.0077, 但 TPR 低 1.0 个百分点、corpus PPL 高 0.61, 因此不存在单方面支配。该对照将完整系统的效应分解为动态 KL、candidate/gate 和 detector 三部分, 避免将检测器增益直接归因于生成算法。

6 总结

本文围绕大语言模型生成文本的统计水印检测问题, 完成了 KGW 方法的复现, 并在统一实验协议下研究逐位置 KL 约束水印及其候选集合、置信门控扩展。实验将参数选择与最终评测严格分离, 对生成文本的来源检测率、语义一致性和语言流畅性进行联合评价, 使不同水印配置能够在同一尺度下比较。

实验结果表明, 逐位置 KL 预算能够以可解释的分布约束调节水印强度, 并形成连续的检测-质量折中。在 $\varepsilon = 0.10$ 的代表性设置下, CA-KL 达到 94.80% TPR@1%FPR、0.6875 SimCSE 和 25.25 corpus PPL, 表现与 KGW 固定偏置方法接近; 当预算继续增大时, 检测率进一步提升, 但语义相似度和困惑度会出现相应损失。因此, 该方法的主要价值不在于单点上完全取代 KGW, 而在于提供了更明确的扰动预算和更细粒度的工作点选择。

此外, 完整方法的结果说明, 候选集合约束和置信门控虽然能够使水印嵌入更贴合当前采样分布, 但也要求检测端同步建模相同的有效位置和统计权重。匹配 weighted-global 检测器将完整方法的 TPR 从标准检测下的 86.40% 提升至 97.80%, 证明生成机制与检测统计的一致性直接影响最终检测能力。综合来看, 本文的实验支持以下结论: KGW 水印具有稳定的可复现性; 逐位置 KL 约束提供了更可控的水印强度调节方式; 面向改进水印流程时, 检测器设计应与生成阶段的约束共同考虑。

7 实验分工

施煌：负责 KGW 原论文阅读、官方仓库复现、C4 数据流程核对，以及报告中方法背景与复现部分的整理。

祖裕柏：负责改进水印生成端的实现与实验执行。主要包括在 KGW logits processor 基础上实现 CA-KL 逐位置 KL 预算求解，将固定 δ 改为按当前位置分布自适应选择的 δ_i ；实现 candidate-aware greenlist 与基于 entropy/top-1 条件的 confidence gate；编写批量生成脚本，完成 KGW、CA-KL 参数网格以及 candidate/gate 相关方法的 validation 扫描和 test 集生成，并整理实验配置、运行日志与生成结果。

黄镇邦：负责检测端、离线评测与结果分析。主要包括实现 standard KGW detector 以及与 candidate/gate 配置一致的 matched weighted-global、matched weighted-winmax detector；设计低 FPR 阈值校准流程并核对独立测试集误报率；完成 continuation-only corpus PPL、prompt/seed 配对 SimCSE 与 prompt-cluster bootstrap 统计；绘制检测率-语义一致性、检测率-PPL 折中曲线和完整方法对比表，并撰写实验结果分析与结论边界。

参考文献

- [1] J. Kirchenbauer, J. Geiping, Y. Wen, J. Katz, I. Miers, and T. Goldstein, “A watermark for large language models,” in *Proceedings of the 40th International Conference on Machine Learning*, vol. 202 of *Proceedings of Machine Learning Research*, pp. 17061–17084, PMLR, 2023.
- [2] J. Kirchenbauer, J. Geiping, Y. Wen, M. Shu, K. Saifullah, K. Kong, K. Fernando, A. Saha, M. Goldblum, and T. Goldstein, “On the reliability of watermarks for large language models,” in *International Conference on Learning Representations*, 2024.
- [3] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, and P. J. Liu, “Exploring the limits of transfer learning with a unified text-to-text transformer,” *Journal of Machine Learning Research*, vol. 21, no. 140, pp. 1–67, 2020.
- [4] S. Zhang, S. Roller, N. Goyal, M. Artetxe, M. Chen, S. Chen, C. Dewan, M. Diab, X. Li, X. V. Lin, T. Mihaylov, M. Ott, S. Shleifer, K. Shuster, D. Simig, P. S. Koura, A. Sridhar, T. Wang, and L. Zettlemoyer, “OPT: Open pre-trained transformer language models,” 2022.
- [5] M. Huo, S. A. Somayajula, Y. Liang, R. Zhang, F. Koushanfar, and P. Xie, “Token-specific watermarking with enhanced detectability and semantic coherence for large language models,” in *Proceedings of the 41st International Conference on Machine Learning*, vol. 235 of *Proceedings of Machine Learning Research*, pp. 20746–20767, PMLR, 2024.